



Universidad
Nacional
de Córdoba



FACULTAD
DE CIENCIAS
ECONÓMICAS

Informe Técnico

Análisis descriptivo, ACP y Conglomerados

Autora: Victoria Pereyra

Legajo: 39733198

Materia: Machine Learning

Año: 2025

0.1. Análisis de la base de datos

La base está compuesta por 90 empresas del sector de servicios de computación. Se analizaron cuatro variables cuantitativas principales: *cantidad de empleados*, *ventas anuales en USD*, *sueldos anuales en USD* e *inversión anual en USD*.

El perfilado inicial muestra un dataset de buena calidad: sin valores faltantes, sin duplicados y con todas las variables numéricas. La variable ID se descartó por su rol meramente identificador.

Una observación relevante es la diferencia de escala: mientras que la cantidad de empleados varía en decenas o centenas, las variables monetarias alcanzan valores en millones de USD. Esta disparidad refuerza la necesidad de aplicar **estandarización** antes de los análisis multivariados.

0.2. Análisis descriptivo univariado

El análisis individual de cada variable permite identificar tendencias centrales, dispersión y forma de las distribuciones.

Resultados principales

- Las variables monetarias presentan **asimetría positiva**, con gran concentración de empresas en valores bajos y algunas con cifras muy elevadas.
- La variable *empleados* muestra una distribución sesgada hacia las empresas pequeñas y medianas, con unos pocos casos de gran tamaño.
- Los diagramas de caja revelan **outliers**, especialmente en ventas e inversión, representando empresas fuera de lo común en el sector.
- Las curtosis calculadas indican distribuciones **leptocúrticas**, con colas más pesadas de lo esperado bajo normalidad.

0.3. Análisis bivariado y correlaciones

Para profundizar en la relación entre variables, se utilizaron matrices de dispersión y correlaciones de Pearson.

Hallazgos clave

- Existe una **correlación positiva fuerte** entre *empleados*, *ventas* y *sueldos*, lo que sugiere un factor común de **escala empresarial**.
- La *inversión* presenta correlaciones más débiles: no todas las empresas invierten proporcionalmente a su tamaño.
- Los porcentajes derivados (inversión relativa, costos) muestran variabilidad, indicando diferencias en estrategias financieras incluso entre empresas similares.




Figura 1: Histograma de ventas




Figura 2: Dispersión inversión vs ventas

- Se identifican valores atípicos que afectan la linealidad de algunos gráficos de dispersión.

0.4. Análisis de Componentes Principales (ACP)

El ACP busca reducir la dimensionalidad de los datos (muchas variables a pocas componentes) conservando la mayor parte posible de la varianza.

Metodología

- Se estandarizo la matriz de datos de empresas y calcula su matriz de covarianzas (*z-score*).
- Luego resuelve un problema de valores y vectores propios:
- Los autovalores indican cuánta varianza explica cada componente.
- Los autovectores (direcciones) son combinaciones lineales de las variables originales que forman las componentes principales (PCs).
- Se analizó la varianza explicada y se construyeron la matriz de correlación y el biplot.

Analisis Resultados ACP

- Los puntos rojos: cada punto es una empresa proyectada en el nuevo sistema de coordenadas (PC1 en el eje X y PC2 en el eje Y).
- Si dos empresas están cerca tienen perfiles de variables parecidos, caso contrario son diferentes en función de las variables originales.
- **Vectores:** representan las variables originales proyectadas en el espacio de los primeros dos componentes.
- **Dirección:** hacia dónde “aporta” más la variable.
- **Longitud:** cuán importante es esa variable en la explicación de la varianza.
- **PC1 (eje X):** es la combinación lineal de variables que explica la mayor varianza posible (por ejemplo, una mezcla de ventas netas + sueldos).
- **PC2 (eje Y):** es la segunda combinación lineal, ortogonal a PC1, que explica la segunda mayor varianza.
- Si dos flechas están **próximas**, esas variables están positivamente correlacionadas.
- Si dos flechas están en **direcciones opuestas**, esas variables están negativamente correlacionadas.
- Si forman un ángulo cercano a 90° , esas variables están **no correlacionadas**.

Interpretación del gráfico obtenido

- Las empresas dispersas en el plano muestran diferencias en su estructura de ventas, costos e inversión.
- **Ventas netas:** el vector apunta hacia la derecha, indicando que PC1 diferencia principalmente empresas por nivel de ventas.

- **Inversión:** el vector apunta hacia arriba, mostrando que PC2 separa a las empresas con mayor peso en inversión.
- **Sueldos pagados USD y costos:** los vectores aparecen cercanos, lo que refleja una alta correlación entre estas variables.




Figura 3: Biplot de los dos primeros componentes principales

0.5. Análisis de Conglomerados

Se aplicaron técnicas de agrupamiento para identificar segmentos homogéneos de empresas. Se vuelven a estandarizar los valores con media = 0 y varianza = 1. Los algoritmos basados en distancia (euclídea) son sensibles a la escala. Estandarizar garantiza que cada variable contribuya por igual. Aplicamos el análisis de componentes principales para trabajar con menos variables y visualizar los valores en 2d. Con el método ward se minimiza la varianza intracluster.

Conglomerados jerárquicos

El dendrograma construido con método de Ward y distancia euclídea sugiere la existencia de **dos conglomerados principales**, con subdivisiones adicionales posibles en tres o cuatro ramas.

K-means

- Se probaron valores de k entre 2 y 8.
- El mejor resultado se obtuvo con $k = 2$ ($silhouette \approx 0,63$), indicando dos grupos bien definidos.
- Para $k = 3$ a $k = 5$, los valores de $silhouette$ permanecieron aceptables ($\approx 0,55$), mostrando segmentaciones más detalladas.




Figura 4: Dendrograma de conglomerados jerárquicos




Figura 5: Segmentación de empresas mediante k-means

0.6. Conclusiones

- El análisis descriptivo evidenció fuerte asimetría y outliers en las variables monetarias, típicos de datos empresariales.
- El análisis bivariado confirmó la existencia de un **factor de escala** que conecta empleados, ventas y sueldos.
- El ACP permitió reducir la información a dos dimensiones principales: **tamaño empresarial** y **estructura relativa de inversión/costos**.
- El análisis de conglomerados mostró dos grupos principales de empresas: de menor escala y de gran escala, con posibilidad de segmentación más fina.
- Estos resultados proporcionan una base sólida para la toma de decisiones estratégicas, comparaciones de desempeño y diseño de políticas diferenciadas según la escala de las empresas.