

Materia: Introducción al Aprendizaje Automático (Machine Learning)

Trabajo Práctico N°2

Apellido y Nombre: Pereyra, Victoria Luz

Legajo: 39733198

Introducción

El presente trabajo tiene como objetivo aplicar y analizar distintos modelos de aprendizaje automático supervisado sobre un conjunto de datos de clientes de una plataforma digital. A través de modelos de regresión polinómica, regresión lineal múltiple y regresión logística, se busca comprender el comportamiento de las compras digitales, su relación con variables de interacción y el grado de predicción que puede alcanzarse sobre la probabilidad de compra final.

2. Análisis del conjunto de datos

El dataset utilizado cuenta con un total de 300 registros que representan diferentes clientes de la plataforma. Cada registro contiene información referente al tamaño del cliente, su antigüedad digital en meses, el porcentaje de compras digitales realizadas, la cobertura del surtido respecto al total disponible, y otros indicadores de comportamiento en el sitio.

Al observar la variable `compra_realizada`, se aprecia que sólo 30 de los 300 registros corresponden a compras efectivamente concretadas, lo que equivale al 10% del total. Este dato indica una proporción baja de conversión, reflejando un comportamiento donde la mayoría de los usuarios exploran la plataforma sin completar la compra.

En cuanto a la variable `porc_compra_dig`, que mide la participación de compras digitales sobre el total, se observa una dispersión considerable, sugiriendo que los usuarios muestran diferentes grados de adopción digital. Por otro lado, la variable `antigüedad_meses` presenta valores bajos en general, lo que implica que gran parte de los clientes son relativamente nuevos en el entorno digital. Finalmente, `cliente_tamaño` se distribuye entre categorías tales como “Small”, “Medium” y “Large”, mostrando que el tamaño del cliente podría incidir directamente sobre la propensión a realizar compras digitales.

3. Modelo de Regresión Polinómica

Previo al análisis, se definió un modelo de regresión polinómica para estimar el nivel de compras digitales (`porc_compra_dig`) en función de la antigüedad del cliente en la plataforma (`antigüedad_meses`). Este modelo busca capturar relaciones no lineales entre ambas variables, considerando la posible existencia de un punto de saturación en el comportamiento de compra.

Los resultados obtenidos para el modelo polinómico de grado $M = 2$ arrojaron un **MAE (Error Absoluto Medio)** de **13.48** y un **MSE (Error Cuadrático Medio)** de **263.25**. Estos valores indican que, en promedio, las predicciones del modelo se desvían aproximadamente 13 unidades del valor real y que el error cuadrático promedio se mantiene moderado, lo que sugiere un ajuste razonable para este nivel de complejidad.




Figura 1: Regresión Polinómica con $M = 2$.

En el gráfico se aprecia cómo la línea roja de la regresión polinómica se ajusta de manera suave a los datos de test (en azul). A medida que el grado polinómico aumenta, se observa una reducción del error de entrenamiento, mientras que el error de validación tiende a aumentar, fenómeno que evidencia el sobreajuste cuando el modelo se vuelve excesivamente flexible.

4. Modelo de Regresión Lineal Múltiple

Para el siguiente análisis se consideraron múltiples variables predictoras con el fin de estimar el porcentaje de compras digitales: `antigüedad_meses`, `minutos_platform`, `productos_agregados` y `productos_removidos`. El modelo de regresión lineal múltiple permitió identificar la influencia simultánea de estos factores sobre la variable objetivo.

Los resultados obtenidos fueron los siguientes:

Cuadro 1: Resumen de métricas del modelo de regresión lineal múltiple.

Métrica	Valor	Interpretación
MAE (Error Absoluto Medio)	13.09	En promedio, las predicciones se desvían 13 unidades del valor real.
MSE (Error Cuadrático Medio)	238.58	Mide el error promedio al cuadrado. Penaliza más los errores grandes.
RMSE (Raíz del MSE)	15.45	Error promedio expresado en la misma escala que la variable objetivo.
RMSLE (Raíz del Error Logarítmico Cuadrático Medio)	0.199	Indica que el error relativo es bajo; útil si los valores varían mucho en magnitud.

El error absoluto medio (MAE) muestra una leve mejora respecto al modelo polinómico, reduciendo la desviación promedio de las predicciones. El MSE y el RMSE confirman un comportamiento estable y sin valores atípicos significativos. Este modelo logra un mejor balance entre precisión y generalización, lo que sugiere que la relación entre las variables explicativas y la respuesta es predominantemente lineal.




Figura 2: Residuos del modelo en función de las predicciones.

El gráfico de errores refleja cómo el modelo lineal alcanza el punto de menor error de valida-

ción, validando la elección de un modelo simple frente a alternativas de mayor complejidad que podrían sobreajustar los datos.

5. Análisis comparativo de modelos

Al comparar la regresión polinómica ($M = 2$) con la regresión lineal múltiple, se observa que ambos modelos presentan un desempeño similar en términos de error medio. Sin embargo, el modelo múltiple logra una mejor generalización y menor error cuadrático medio, por lo que se considera la opción más adecuada para predecir el porcentaje de compras digitales en función de múltiples variables explicativas.

6. Modelo de Regresión Logística

En esta etapa, se desarrolló un modelo de regresión logística con el objetivo de predecir la probabilidad de que una compra sea finalmente realizada (`compra_realizada`). Las variables predictoras incluidas fueron: `cliente_tamaño`, `porc_compra_dig`, `porc_cobertura_surtido`, `duracion_compra` y `productos_agregados`.

Los resultados obtenidos mostraron una excelente capacidad predictiva. La matriz de confusión evidenció los siguientes valores:

$$\begin{bmatrix} 54 & 0 \\ 1 & 5 \end{bmatrix}$$

De los 60 casos evaluados, el modelo clasificó correctamente 59, alcanzando una **exactitud del 98.3 %**. La clase negativa (no compra) fue correctamente identificada en el 100 % de los casos, mientras que la clase positiva (compra realizada) tuvo una tasa de acierto del 83 %. En términos de desempeño global:

- **Precisión (compra realizada):** 1.00
- **Recall (sensibilidad):** 0.83
- **F1-Score:** 0.91
- **Accuracy total:** 0.983

El porcentaje de concordancia del test alcanzó el 90 %, lo cual indica una fuerte correspondencia entre las predicciones del modelo y los resultados reales. Sin embargo, al evaluar la sensibilidad y especificidad, se observa una **Sensibilidad = 0.0** y una **Especificidad = 1.0**, lo que sugiere que el modelo tiende a clasificar correctamente los casos negativos pero podría requerir un mejor ajuste para identificar los positivos con mayor precisión.




Figura 3: Curva ROC del modelo logístico.

La curva ROC confirma un excelente desempeño general del modelo logístico, con un área bajo la curva (AUC) cercana a 1, lo que respalda su capacidad discriminante.

Conclusión

A lo largo de este trabajo se abordaron tres enfoques principales de modelado: la regresión polinómica, la regresión lineal múltiple y la regresión logística. Los dos primeros permitieron estimar y comparar diferentes niveles de error en la predicción del porcentaje de compras digitales, destacándose la regresión múltiple como el modelo con mejor balance entre precisión y simplicidad. Por su parte, la regresión logística demostró una excelente capacidad para clasificar las compras realizadas, alcanzando altos niveles de exactitud y especificidad.

En síntesis, los resultados obtenidos refuerzan la importancia de seleccionar el modelo más adecuado según la naturaleza de la variable objetivo: continua (regresión) o categórica (clasificación), garantizando así predicciones más confiables y útiles para la toma de decisiones en entornos comerciales digitales.